

UNIVERSIDAD MAYOR DE SAN ANDRÉS
Facultad de Ciencias Puras y Naturales
Carrera de Informática

Procesamiento del Lenguaje Natural — Segundo parcial

Clasificación automática de comentarios universitarios

Bolsa de palabras, TF-IDF, PCA, Naive Bayes y SVM sobre un corpus de 120 comentarios en tres categorías

---

Integrantes del grupo

Nombres	**C.I.**
Andrés Maximiliano Espinoza Romero	6783133
Iver Samuel Medina Balboa	6721489

Docente: **M. Sc. Rosa Flores Morales**

La Paz, Bolivia, noviembre de 2026

Tabla 1: Fragmento de la matriz BoW (entrenamiento, texto procesado).

Doc.	Clase	habilit	formulari	inscripcion	atencion	bibliotec	horari	ayud	grup
doc0	consulta	1	1	1	0	0	0	0	0
doc1	consulta	0	0	0	1	1	1	0	0
doc2	positiva	0	0	0	0	0	0	1	1

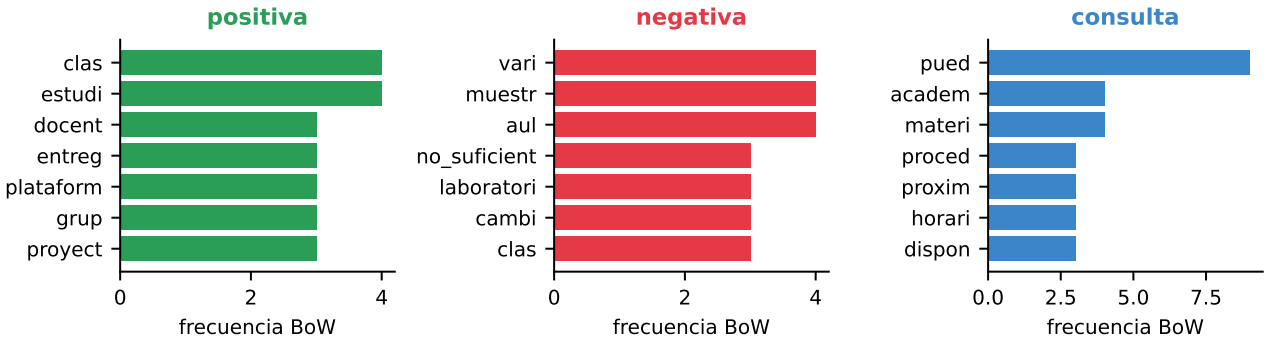


Figura 1: Siete términos más frecuentes por clase en el entrenamiento (BoW).

1. Problema y objetivo

La universidad recibe comentarios escritos y necesita clasificarlos para atender primero los que lo requieren. La pregunta de investigación es: *¿qué representación de los textos (BoW o TF-IDF) y qué algoritmo (Naive Bayes o SVM) dan mejores resultados?* Se entrenan y comparan los cuatro modelos resultantes sobre exactamente la misma partición, con tres categorías: *positiva*, *negativa* y *consulta*. El adelanto honesto es que el conjunto es pequeño (120 comentarios) y que ningún modelo supera con holgura el azar; por eso el informe pone tanto peso en *cómo* se compara y en los errores como en la tabla final.

2. Datos y preparación (Fase 1)

Datos. Hoja Excel con 120 comentarios (columnas `comentario`, `categoria`), 40 por clase (razón 1:1, de 7 a 12 palabras cada uno). La validación de calidad no encontró nulos, textos vacíos, contradicciones ni duplicados exactos (se revisaron para evitar fuga de datos entre entrenamiento y prueba).

Limpieza (`limpiar_texto`): minúsculas; emojis y emoticones convertidos a tokens (`emopos`/`emoneg`); eliminación de URL, menciones y cifras; quitar tildes conservando la ń; reducción de alargamientos (“buenooo” → “bueno”); puntuación fuera; *diccionario propio* para jerga y faltas (`xq`→`porque`, `inscrip`→`inscripcion`, `exelente`→`excelente`); *stop words* de NLTK (313, de las que quedan 295 efectivas) *conservando* 21 negaciones y palabras de contraste o intensidad (`no, nunca, sin, ni, pero, muy, poco, bien, mal,...`), porque “no me gustó” y “me gustó” son opuestos; stemming Snowball en español; y *marcado de negación*: negador + palabra siguiente forman un solo token (`no_gust`). Resultado: el vocabulario baja de 451 tipos (texto original) a 397 (sin stop words) y 317 (con stemming).

Partición. 80/20 *estratificada* con semilla 42: 96 comentarios de entrenamiento (32 por clase) y 24 de prueba (8 por clase). La limpieza es determinista y no aprende de los datos, por lo que aplicarla antes de dividir no filtra información; en cambio, *vectorizadores y PCA se ajustan solo con entrenamiento* (dentro de `Pipeline` en la validación cruzada).

3. Representación vectorial (Fase 2)

3.1 Bag of Words

`CountVectorizer` ajustado con el entrenamiento da una matriz de 96×282 (282 términos); la de prueba es 24×282 y 41 de sus 132 tokens (31 %) no existen en el vocabulario y se ignoran. La matriz es 98.1 % ceros. Cada fila es un comentario, cada columna una palabra, cada celda su frecuencia; se pierde el orden, por eso importa el marcado de negación.

Qué palabras distinguen a las categorías. Con log-odds suavizado (positiva vs. negativa, términos con frecuencia ≥ 2): lo positivo se asocia a `ayud`, `grup`, `comprend`, `explic`, `bien`, `interes`; lo negativo a `vari`, `no_suficient`, `demasi`, `lent`, `poc`, `tard`; las consultas, a `pued` (9 apariciones, ninguna en las otras clases), `solicit`, `proced`, `proxim`. Las palabras de consulta son más *estructurales* (preguntar) que de polaridad.

Tabla 2: Pesos TF-IDF de los términos de tres documentos de entrenamiento (doc0 y doc1: consulta; doc2: positiva; frecuencia BoW = 1 en todos).

Doc.	Término	idf	peso	Doc.	Término	idf	peso
doc0	`habilit`	4.882	0.640	doc2	`compañer`	4.882	0.462
doc0	`formulari`	4.476	0.587	doc2	`resolv`	4.882	0.462
doc0	`inscripcion`	3.783	0.496	doc2	`dud`	4.476	0.424
doc1	`atencion`	4.476	0.640	doc2	`ayud`	4.188	0.396
doc1	`bibliotec`	3.965	0.567	doc2	`grup`	3.965	0.375
doc1	`horari`	3.629	0.519	doc2	`estudi`	3.272	0.310

Tabla 3: Varianza explicada por los primeros componentes (de 282 posibles).

	PC1	PC2	PC3	PC4	PC5
Varianza explicada (%)	2.77	2.52	2.35	2.25	2.16
Varianza acumulada (%)	2.77	5.29	7.64	9.89	12.05

3.2 TF-IDF

Se pondera cada término por $\text{tf-idf}(t,d) = \text{tf}(t,d) \cdot \text{idf}(t)$ con $\text{idf}(t) = \ln \frac{1+n}{1+\text{df}(t)} + 1$ (versión suavizada de scikit-learn) y se normaliza cada vector con norma L2. Se verificó a mano: para `habilit` (df = 1 de $n = 96$), idf = $\ln(97/2) + 1 = 4{,}8816$ y peso 0,6400, idénticos a los de scikit-learn.

Interpretación. Los términos más comunes (`pued`, `estudi`: 9 de 96 documentos; idf = 3,27) pesan menos que los raros (1 documento; idf = 4,88). Una palabra presente en casi todos los comentarios tendría idf $\to$ 1 (el mínimo): peso bajo *no* significa que carezca de importancia, sino que *no ayuda a distinguir* un comentario de otro; "universidad" puede ser central para el tema y a la vez inútil para separar clases. En este corpus la diferencia entre comunes y raros es modesta porque ningún término aparece en más de 9 documentos.

4. Reducción de dimensionalidad con PCA (Fase 3)

Se ajustó `PCA` sobre la matriz TF-IDF *solo con entrenamiento*; el test se proyecta con la misma transformación.

Interpretación. Con dos componentes se conserva solo el 5.3 % de la variabilidad; hacen falta 59 componentes para el 80 % y 73 para el 90 %: la varianza está repartida casi uniformemente, rasgo típico de textos cortos y dispersos. En el plano PC1–PC2 las tres categorías **se mezclan**: el coeficiente de silueta (por categoría) es −0,049 en 2D, −0,001 con 59 componentes y 0,000 en el espacio original de 282 dimensiones. Los componentes reflejan sobre todo *tema* y no polaridad (PC1: `academ`, `sistem`, `muestr`, `pued`; PC2: `pued`, `virtual`, `aul`, `plataform`), lo esperable en un método no supervisado que maximiza varianza y no separación entre clases. Mezcla en 2D no implica que ningún clasificador pueda separar las clases (pregunta 3 de la sección 8); pero aquí tampoco aparece una estructura que lo prometa, y así se comprobó: TF-IDF $\to$ PCA (59 comp.) $\to$ SVM lineal dio acc. 0,417 y F1 0,412, por debajo de TF-IDF + SVM sin PCA (0,458 / 0,451). Por eso el PCA se usa aquí como *análisis exploratorio* y no entra en el modelo final.

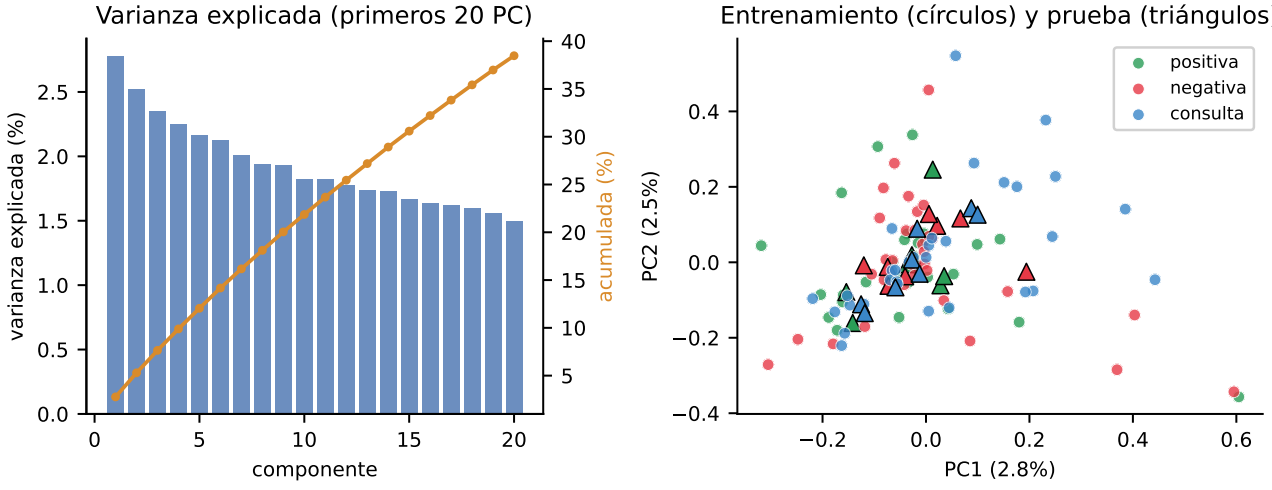


Figura 2: Izquierda: varianza explicada y acumulada. Derecha: comentarios en PC1–PC2 (TF-IDF).

Tabla 4: Resultados en prueba (formato pedido) y métricas complementarias. VC = validación cruzada estratificada repetida 5×3 sobre los 120 comentarios (media ± desv. estándar entre 15 pliegues).

Representación	Clasificador	Accuracy	F1 macro	Prec. macro	Recall macro	Recall neg.	F1 macro VC
BoW	Naive Bayes	0.417	0.385	0.444	0.417	0.500	0.391 ± 0.070
TF-IDF	Naive Bayes	0.375	0.347	0.409	0.375	0.375	0.400 ± 0.070
BoW	SVM	0.333	0.306	0.324	0.333	0.250	0.386 ± 0.084
TF-IDF	**SVM**	**0.458**	**0.451**	**0.519**	**0.458**	**0.500**	**0.418 ± 0.068**

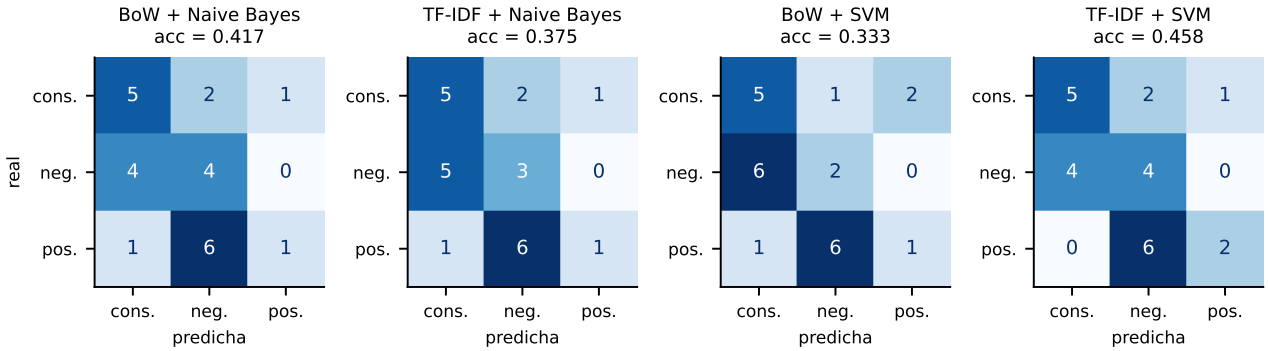


Figura 3: Matrices de confusión en prueba (filas: clase real; columnas: predicha).

5. Clasificadores (Fase 4)

Naive Bayes multinomial. Asigna la clase de mayor probabilidad a posteriori bajo el supuesto "ingenuo" de independencia de las palabras dada la clase:

$$\log P(c \mid d) = \log P(c) + \sum_{w \in d} n_{w,d} \log P(w \mid c), \qquad \hat{c} = \arg\max_{c} \log P(c \mid d).$$

Cada palabra aporta un voto ponderado por $\log P(w \mid c)$ (estimada con suavizado de Laplace/α). Se verificó a mano con el primer comentario de prueba (*"La conexión a internet del campus permitió trabajar sin interrupciones"*, real: positiva): con prior uniforme ($\log P(c) = -1{,}099$) los log-posteriores fueron $-34{,}30$ (consulta), $-28{,}61$ (negativa) y $-32{,}00$ (positiva), es decir $P(\text{negativa} \mid d) = 0{,}964$, idéntico a `predict_proba`. Es un error ilustrativo: la palabra `sin_interrupcion` lleva el marcador de negación y ese tipo de token, en el entrenamiento, aparece casi solo en comentarios negativos (sección 7.1).

SVM. Busca el hiperplano $\mathbf{w} \cdot \mathbf{x} + b = 0$ de *margen máximo*; solo los vectores de soporte (los puntos más cercanos a la frontera) lo determinan. El parámetro C regula el compromiso entre margen ancho y errores de entrenamiento, y un *kernel* (RBF) permite fronteras no lineales; con tres clases se combinan clasificadores uno-contra-uno. La Fig. 4(izq.) ilustra la idea en 2D (*positiva* contra el resto; 66 de 96 puntos son vectores de soporte, señal de que las clases no son separables en ese plano); los modelos reales trabajan en el espacio completo.

Diseño. Cada modelo es un `Pipeline` (vectorizador → clasificador); los hiperparámetros se eligen con `GridSearchCV` (5 pliegues, F1 macro) *solo sobre entrenamiento*: n-gramas $(1,1)$ o $(1,2)$, `min_df` 1 o 2, $\alpha \in \{0{,}1, 0{,}3, 0{,}5, 1\}$ para NB y $C \in \{0{,}1, 1, 10\}$ con kernel lineal o RBF para SVM (`class_weight=balanced`). Seleccionados: BoW+NB $\alpha = 0{,}3$; TF-IDF+NB $\alpha = 1$; BoW+SVM lineal, $C = 1$, n-gramas $(1,2)$; TF-IDF+SVM RBF, $C = 1$. Las cuatro configuraciones alcanzan F1-CV interno de solo 0,41–0,45.

6. Resultados

Los cuatro modelos se evaluaron sobre el *mismo* conjunto de prueba (24 comentarios; azar = 1/3).

Lectura. TF-IDF+SVM es el mejor en ambos criterios, pero con una ventaja pequeña. Con 24 comentarios de prueba una exactitud de 0,458 (11 aciertos) tiene un margen de error aproximado de ±0,20, así que las diferencias entre modelos en una sola partición son *indistinguibles del ruido*. La validación cruzada (mismos 15 pliegues para los cuatro) lo confirma: las medias van de 0,386 a 0,418 con desviaciones de 0,07–0,08. En la comparación pareada por pliegue, TF-IDF − BoW da $+0{,}009 \pm 0{,}035$ en NB (TF-IDF gana en 3 de 15 pliegues, empata en 7) y $+0{,}033 \pm 0{,}081$ en SVM (gana en 10 de 15); SVM − NB da $-0{,}006 \pm 0{,}053$ con BoW y $+0{,}018 \pm 0{,}056$ con TF-IDF. Todas las diferencias son menores que su desviación.

7. Análisis crítico (Fase 5)

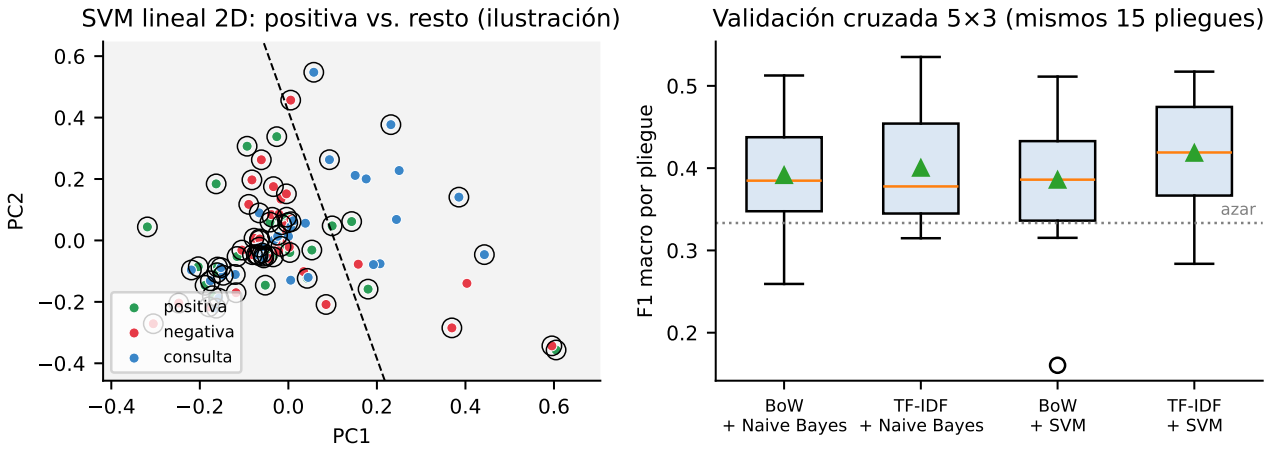


Figura 4: Izquierda: frontera y margen de un SVM lineal en 2D (ilustración). Derecha: F1 macro por pliegue en la validación cruzada 5×3.

Tabla 5: Predicción de los cuatro modelos sobre cinco comentarios nuevos (B = BoW, T = TF-IDF; ✓= acierto).

Comentario (real)		B+NB	T+NB	B+SVM	T+SVM
"Excelente atención en la biblioteca, el personal fue muy amable y rápido."	positiva	pos. ✓	pos. ✓	pos. ✓	pos. ✓
"Pésimo servicio, llevo tres semanas esperando una respuesta y nadie me atiende."	negativa	cons.	cons.	cons.	cons.
"Qué maravilla, otra vez sin internet en el laboratorio, justo lo que necesitaba." (ironía)	negativa	cons.	cons.	cons.	neg. ✓
"xq la inscrip es tan lenta, ntp pero deberian mejorarla!!!" (jerga)	negativa	pos.	neg. ✓	cons.	neg. ✓
"¿Sera que puedo inscribirme ahora?"	consulta	cons. ✓	cons. ✓	cons. ✓	cons. ✓
Aciertos		2/5	3/5	2/5	4/5

7.1 Errores de clasificación

En prueba, 16 de 24 comentarios fueron mal clasificados por al menos un modelo y 13 por *los cuatro*. El error dominante es **positiva → negativa**: de los 8 comentarios positivos de prueba, 6 se clasifican como negativos en los cuatro modelos (recall de positiva: 0,12–0,25). Los datos sugieren dos causas, ambas verificables:

- **Atajo de la negación.** En el entrenamiento, 13 de los 32 comentarios negativos contienen un token marcado (`no_`/`sin_`) frente a 1 de 32 positivos y 0 de 32 consultas. Un positivo como "…trabajar *sin* interrupciones" o "…sin problemas" activa ese marcador y es empujado hacia *negativa*, aunque "sin" ahí exprese algo bueno. El marcado trata igual la negación de algo bueno que de algo malo.
- **Vocabulario nuevo.** El 31 % de los tokens de prueba (41 de 132) no está en el vocabulario de entrenamiento (34 % en los positivos), así que el modelo decide con muy poca evidencia. Con 96 comentarios de entrenamiento y 282 términos, la matriz es casi vacía.

En la validación cruzada del mejor modelo hubo 68 errores de 120 (56.7 %); 16 negativos fueron clasificados como positivos y 14 positivos como negativos. Comparando TF-IDF+NB con TF-IDF+SVM en prueba: ambos aciertan en 9 comentarios, ambos fallan en 13 y solo en 2 acierta el SVM y falla NB (ninguno al revés).

Consecuencias. Negativo → positivo es el error más costoso (una queja prioritaria queda sin atender); positivo → negativo genera trabajo innecesario; clasificar como negativa una consulta prioriza de más, y una queja clasificada como consulta recibe atención tardía. Por eso se vigila el recall de la clase negativa: 0,50 en prueba para BoW+NB y TF-IDF+SVM, y sólo 0,25–0,35 en VC (TF-IDF+SVM: 0,35), cifras muy bajas para uso real.

7.2 Cinco comentarios nuevos

El comentario claramente positivo y la consulta se clasifican bien en los cuatro modelos. La queja "Pésimo servicio…" la toman por consulta los cuatro: es una queja explícita pero con vocabulario poco visto en el entrenamiento (hipótesis: "pésimo" no aporta y el resto, "semanas", "respuesta", "esperando", se parece a una consulta). La **ironía** ("qué maravilla" suena positiva en bolsa de palabras) solo la acierta TF-IDF+SVM, quizá por azar dado el tamaño de muestra; y la **jerga** se beneficia del diccionario propio ("xq", "inscrip"), pero BoW+NB y BoW+SVM igual fallan. Cinco casos no permiten concluir superioridad; ilustran qué tipos de texto fallan.

7.3 Elección del modelo

Se elige TF-IDF + SVM (RBF, $C = 1$): es el mejor en F1 macro de prueba (0,451), en F1 macro medio de VC (0,418), en recall de la clase negativa en VC (0,35) y en los cinco comentarios nuevos (4/5). Se decide por F1 macro y recall negativo, no por exactitud de una partición, porque el costo de error es asimétrico. Hay que ser explícito en que *la ventaja sobre TF-IDF+NB (*0,018*) es menor que la variación entre pliegues (*0,068*)*: estadísticamente son comparables. Naive Bayes ofrecería una explicación directa por palabra y entrenamiento instantáneo; el SVM, más robusto con vocabulario disperso. La decisión es provisional: ningún modelo es utilizable sin revisión humana con estas cifras (accuracy $\approx$ 0,42 frente a 0,33 del azar).

7.4 Mejoras propuestas

1. **Revisar el marcado de negación** (mejora con evidencia propia). En una ablación con los mismos 15 pliegues, TF-IDF+SVM con solo limpieza básica (sin stemming ni marcado) obtuvo F1 macro $0{,}479 \pm 0{,}098$ frente a $0{,}418 \pm 0{,}068$ con el preprocesamiento completo ($-0{,}061$ al aplicarlo). La diferencia está dentro del ruido, pero apunta a que el atajo de `sin_`/`no_` perjudica más de lo que ayuda: conviene marcar solo `no`/`nunca`, o no marcar "sin", y repetir el experimento.
2. **Más datos y diccionario ampliado** con vocabulario real de la universidad (más ejemplos de ironía, faltas, y sinónimos de queja).
3. **Revisión humana** de los comentarios en que NB y SVM discrepan o la confianza es baja, y **léxico de polaridad en español** como característica adicional.

8. Preguntas de pensamiento crítico

1. **BoW vs. TF-IDF.** Una palabra en casi todos los comentarios tiene idf ≈ 1 y peso bajo porque no discrimina; no por eso carece de importancia semántica.
2. **NB 85 % vs. SVM 82 %.** No elegiría NB automáticamente: revisaría F1 macro y recall por clase, la matriz de confusión, la variabilidad en VC repetida (tres puntos pueden ser ruido con un test pequeño), la estabilidad ante vocabulario nuevo y el costo de cada error.
3. **PCA mezclado.** No implica que nada pueda separarlos: dos componentes retienen una fracción mínima de la varianza y PCA no busca separar clases (aquí, sin embargo, tampoco hubo mejora al usarlo).
4. **Errores.** Negativo $\rightarrow$ positivo: queja sin atender (el más grave). Consulta $\rightarrow$ negativa: priorización innecesaria.
5. **Generalización.** No: acertar en prueba solo garantiza rendimiento sobre textos parecidos a los de entrenamiento; ironía, faltas y vocabulario nuevo lo degradan (ver cinco comentarios nuevos, 31 % de tokens desconocidos en prueba).
6. **Desbalance (90 de 120 en una clase).** Siempre predecir la mayoritaria daría 75 % de accuracy sin aprender nada; hay que usar F1 macro, recall/precisión por clase, estratificación y `class_weight`.
7. **Diseño experimental.** Comparar con los *mismos* pliegues (VC estratificada repetida, semilla fija), reportar la diferencia pareada y ajustar el vectorizador dentro del `Pipeline` solo con datos de entrenamiento: así la mejora no se debe a una partición distinta.

9. Conclusiones y limitaciones

- **Mejor combinación observada: TF-IDF + SVM** (acc. 0,458, F1 macro 0,451 en prueba; $0{,}418 \pm 0{,}068$ en VC), con ventaja pequeña y no concluyente frente a las demás; con SVM, TF-IDF gana a BoW en 10 de 15 pliegues; con NB casi no hay diferencia.
- El PCA mostró que las categorías se mezclan (varianza en 2D: 5.3 %) y no mejoró la clasificación; es útil para explorar, no para el modelo final.
- La principal debilidad es el pre-procesamiento y los datos: el marcado de negación crea un atajo sesgado hacia *negativa*, y 120 comentarios dejan casi vacía la matriz y 31 % de vocabulario nuevo en prueba.
- **Limitaciones:** partición única de 24 comentarios en la comparación principal; la VC sobre los 120 reutiliza hiperparámetros elegidos con el 80 % de esos mismos datos, por lo que es algo optimista y sirve para comparar modelos, no para prometer un rendimiento; un solo corpus pequeño y de redacción regular (7–12 palabras); no se sobreestima: los resultados son válidos para este conjunto.

10. Código y repositorio

El proyecto completo está disponible en dos lugares:

- **GitHub:** `https://github.com/ismedinab96/2doParcialPLN`
- **Notebook ejecutado en Google Colab:** `https://colab.research.google.com/drive/1isQNzPc3NMtGnqyKm3caw4IIl`
  `usp=sharing`

El repositorio incluye el notebook (semilla 42, ejecutable de punta a punta), los datos, los artefactos y el dashboard de defensa. Para reproducir: `pip install -r requirements.txt` y ejecutar el notebook.